Des actions aux cryptomonnaies : une approche par deep learning pour l'arbitrage statistique

Ndoumbé Bayo
Tania Admane
Tea Toscan Du Plantier

Avril 2026

Table des matières

1 Présentation du modèle **2**

1.1 Construction des portefeuilles d'arbitrage . . . 2

1.1.1 Le modèle Fama-French . . . 2

1.1.2 Le modèle PCA . . . 3

1.1.3 Le modèle IPCA . . . 3

1.2 Extraction des signaux . . . 3

1.2.1 Les modèles de signal paramétriques (benchmarks) . . . 3

1.2.2 L'architecture CNN pour les motifs locaux . . . 4

1.2.3 Le Transformer pour les dépendances globales . . . 4

1.3 Allocation optimal du capital . . . 5

1.4 Résultats principaux du papier . . . 5

2 Implémentation **5**

2.1 Choix de la classe d'actifs et modèle de facteurs retenu . . . 5

2.1.1 Les cryptomonnaies . . . 6

2.1.2 Pourquoi le PCA plutôt que Fama-French ou IPCA . . . 6

2.2 Collecte et préparation des données . . . 6

2.2.1 Filtrage par capitalisation . . . 6

2.2.2 Extraction des facteurs PCA et estimation des résidus . . . 7

2.2.3 Paramètres choisis . . . 7

2.3 Modèles benchmarks . . . 7

2.3.1 Ornstein-Uhlenbeck + Feedforward Neural Network . . . 8

2.3.2 Transformation de Fourier + Feedforward Neural Network . . . 8

2.3.3 CNN+Transformer . . . 8

2.4 Méthode d'entrainement . . . 8

3 Résultats **9**

3.1 Comparaison des performances . . . 9

3.2 Analyse de la sensibilité aux hyperparamètres . . . 9

3.3 Analyse comparative des rendements cumulés . . . 10

3.4 Analyse du turnover . . . 11

3.5 Robustesse aux frictions de marché . . . 11

4 Conclusion **12**

1 Présentation du modèle

Ce rapport présente notre implémentation et notre adaptation de l'article Deep Learning Statistical Arbitrage de Guijarro-Ordonez, Pelger et Zanotti (2022). L'objectif est double : comprendre la méthodologie proposée, puis en évaluer la pertinence sur une autre classe d'actifs. Nous l'appliquons ici aux cryptomonnaies, en remplacement des actions américaines du SP 500 considérées dans l'étude originale.

L'article propose une approche globale de l'arbitrage statistique basée sur le deep learning. L'objectif est d'identifier et d'exploiter les écarts de prix temporaire entre des actifs similaires. Leur analyse empirique est menée sur les actions américaines du S&P 500 sur la période 1998-2016. Les auteurs décomposent le problème d'arbitrage en trois composantes : la construction de portefeuilles d'arbitrage, l'extraction de signaux temporels d'arbitrage et l'allocation optimale du capital sous contraintes. Contrairement aux méthodes classiques qui traitent ces étapes séparément, leur modèle les regroupe en un seul système entraîné de bout en bout.

1.1 Construction des portefeuilles d'arbitrage

La première étape consiste à construire des portefeuilles résiduels à l'aide de modèles d'évaluation. Pour chaque actif, les auteurs définissent le résidu comme :

$$\varepsilon_{n,t} = R_{n,t} - \beta_{n,t-1}^T \cdot F_t$$

où $R_{n,t}$ est le rendement excédentaire de l'actif n au temps t, F_t sont les facteurs de risque et $\beta_{n,t-1}$ sont les loadings factoriels estimés sur une fenêtre glissante. Ce résidus représente la différence entre le rendement réel et le rendement prédit par les facteurs de risque systématiques. Il constitue le portefeuille d'arbitrage. Un résidu positif indique que l'actif surperforme son risque factoriel, tandis qu'un résidu négatif suppose le contraire.

Pour qu'un résidu puisse servir de signal d'arbitrage, il doit respecter trois propriétés fondamentales.

1. **Moyenne nulle :** $\mathbb{E}[\varepsilon_{n,t}] = 0$. Cela signifie qu'un écart positif ou négatif est temporaire et est destiné à s'annuler.
2. **Orthogonalité aux facteurs :** les résidus sont par construction, orthogonalisés par rapport aux facteurs de risque. Cela siginfie que la covariance entre chaque résidu et chaque facteur est nulle. Par conséquent, ils ne sont pas exposés aux grandes tendnaces du marché.
3. **Faible corrélation croisée :** Les résidus d'actifs différents sont seulement faiblement corrélés.

Grâce à ces propriétés, les résidus peuvent être traités comme des signaux d'arbitrage relativement purs. Pour mettre en oeuvre cette approche, le papier explore trois modèles de facteurs : Fama-French, PCA et IPCA.

1.1.1 Le modèle Fama-French

Le modèle Fama-French est un modèle d'évaluation des actifs très utilisé en finance. Il explique les rendements d'une action par son exposition à plusieurs facteurs de risques systématiques. Dans sa version à 5 facteurs, le modèle inclut le facteur de marché (Mkt-RF), le facteur de taille (SMB), le facteur de valeur (HML), le facteur de rentabilité (RMW) et le facteur d'investissement (CMA). Chaque facteur est construit à partir de données comptables et boursières. Les auteurs utilisent

égalemet une extension à 8 facteurs incluant le momentum (UMD) et les facteurs de retournement court et long terme (ST_Rev et LT_Rev). Les loadings β sont estimés par régression linéaire sur une fenêtre glissante de 60 jours. L'avantage principal est l'interpréabilité économique des facteurs.

1.1.2 Le modèle PCA

Le modèle PCA (Principal Component Analysis) est une approche qui nécessite aucune donnée externe. Il extrait des facteurs latents directement à partir des rendements des actifs en capturant le maximum de variance commune. Les loadings β sont estimés par regression linéaire sur une fenêtre de 60 jours comme dans le modèle Fama-French. Le plus gros inconvénient de cette méthode est l'absence d'interprétabilité.

1.1.3 Le modèle IPCA

Le modèle IPCA (Instrumented PCA) est une extension du PCA qui intégre des caractéristiques d'entreprises pour guider l'estimation des loadings. L'idée centrale est que les loadings dépendent linéairement des caractéristiques de l'entreprise : $\beta_{i,t} = \Gamma^\top z_{i,t}$ est un vecteur de L caractéristiques (taille, momentum, rentabilité, etc) et Γ est une matrice de paramètres à estimer. Par conséquent, le modèle devient :

$$R_{i,t+1} = (\Gamma^\top z_{i,t})^\top F_{t+1} + \varepsilon_{i,t+1}$$

Les facteurs F_t et la matrice Γ sont estimés par moindres carrés alternés (alternating least squares). L'avantage de l'IPCA est qu'il utilise l'information des caractéristiques pour obtenir des loadings plus précis et qui varie dans le temps. Le papier montre que l'IPCA atteint les meilleures performances (Sharpe ratio supérieur à 4).

1.2 Extraction des signaux

Une fois les résidus obtenus, l'étape suivante consiste à extraire des signaux temporels à partir de leur historique. Le modèle prend en entrée les L derniers résidus cumulés et produit un signal $\theta_{i,t-1}$ qui résume l'information importante pour le trading. Les auteurs proposent une méthode basée sur un transformer convolutionnel et comparent plusieurs modèles plus simples pour évaluer la plue value de leur approche.

1.2.1 Les modèles de signal paramétriques (benchmarks)

Les auteurs introduisent plusieurs modèles de signal plus simples qui servent de benchmarks. Le premier est le modèle d'Orstein Uhlenbeck (OU) qui suppose que le processus des résidus cumulés suit un retour à la moyenne :

$$dX_t = \kappa(\mu - X_t)dt + \sigma dB_t$$

.

Les paramètres κ, μ et σ sont estimés par maximum de vraissemblance sur chaque fenêtre de 30 jours et le signal est constitué des paramètres estimés $(\hat{\kappa}, \hat{\mu}, \hat{\sigma}, X_L, R^2)$. Ce modèle classique est très utilisé dans la littérature. Le second modèle est basé sur une transformée de Fourier rapide (FFT). On décompose la série des résidus cumulés en fréquence et on conserve les coefficients des premières

harmoniques comme signal. Enfin, le troisième modèle est un réseau feedforward (FFN) appliqué directement aux résidus bruts ou aux coefficients de Fourier.

1.2.2 L'architecture CNN pour les motifs locaux

L'architecture combine deux types de réseaux de neurones. La première couche applique $D = 8$ filtres de taille $D_{size} = 2$ jours sur l'entrée qui est une matrice de dimension (N, L) oùN est le nombre d'actifs et $L = 30$ le nombre de jours. Chaque filtre d et chaque position l, on calcule :

$$y_{l,d}^{(0)} = b_d^{(0)} + \sum_{m=1}^{D_{size}} W_{d,m}^{(0)} x_{l-m+1}^{(0)}$$

où $x^{(0)}$ sont les résidus cumulés. Cette opération produit une matrice de features. On applique ensuite une normalisation par instance (Instance Normalization) et une fonction d'activation ReLu :

$$x_{l,d}^{(1)} = \text{ReLU}\left(\frac{y_{1,d}^{(0)} - \mu_d^{(0)}}{\sigma_d^{(0)}}\right)$$

.

La deuxième couche applique aussi des filtres de taille 2, mais cette fois sur les features extraites avec 8 filtres en entrée et 8 en sortie. Au total, le CNN extrait des motifs locaux sur des fenêtre de quelques jours. Chaque filtre apprend à reconnaître un pattern spécifique comme une tendance haussière sur deux jours ou une tendance à la baisse.

1.2.3 Le Transformer pour les dépendances globales

La sortie du CNN est une matrice $\tilde{x} \in \mathbb{R}^{L \times D}$ qui représente pour chaque jour de la fenêtre, l'activation des D filtres. Cette matrice est ensuite traitée par un Transformer. Le mécanisme clé est l'attention multi-têtes. On projet $\tilde{x}$ dans trois espaces différents : les queries $Q_i = \tilde{x}W_i^Q + b_i^Q$, les keys $K_i = \tilde{x}W_i^K + b_i^K$, et les values $V_i = \tilde{x}W_i^V + b_i^V$, où $i = 1, \ldots, H$ est l'indice de la tête d'attention (avec $H = 4$ dans le papier). Le poids d'attention entre deux positions l et j est donné par :

$$\alpha_{l,j,i} = \frac{\exp(K_{i,l} \cdot Q_{i,j})}{\sum_{m=1}^{L} \exp(K_{i,l} \cdot Q_{i,m})}$$

.

L'état caché de chaque tête est donné par

$$h_{i,l} = \sum_{j=1}^{L} \alpha_{l,j,i} V_{i,j}$$

.

Les états de toutes les têtes sont ensuite concaténés et projetés inéairement :

$$h^{\text{proj}} = \text{Concat}(h_1, \ldots, h_H) W^O + b^O$$

.

Cela permet au modèle d'apprendre des dépendances temporelles complexes. Chaque tête peut se concentrer sur un type de relation différent (par exemple une tête peut apprendre à détecter

des tendances à long terme alors qu'une autre capte les tendances à court terme). Le signal final $\theta^{\text{CNN+Trans}}$ est la projection du dernier pas de temps h_L^{proj} qui résume l'information de toute la fenêtre en un vecteur de dimension H (4 dans le papier). Il résume donc tout ce que le modèle a jugé pertinent dans les jours passés (tendances, cycles, etc). Ce signal est ensuite utilisé comme entrée du réseau d'allocation.

1.3 Allocation optimal du capital

Le signal extrait $\theta_{n,t-1}$ est ensuite transformé en poids de portefeuille par un réseau feedforward (FFN). Le FFN qu'ils utilisent est un petit réseau à plusieurs couches. La couche de sortie est une couche linéaire suivie d'une tangente hyperbolique (tanh) qui force chaque poids à être compris entre -1 et 1. Le poids final est obtenu en projetant ces poids sur l'espace des actifs via la matrice Φ_{t-1} définie précédemment.

$$w_{t-1}^{R} = \frac{w_{t-1}^{\epsilon\top}\Phi_{t-1}}{\|w_{t-1}^{\epsilon\top}\Phi_{t-1}\|_1}$$

.

Cette normalisation garantit que la somme des valeurs absolues des poids sur les actions est égale à 1. L'objectif est de maximiser le ratio de Sharpe annualisé :

$$\max \frac{\mathbb{E}[w_{t-1}^{R\top}R_t]}{\sqrt{\text{Var}(w_{t-1}^{R\top}R_t)}}$$

Ce qui rend l'approche particulièrement intéressante est que l'extraction des signaux et l'allocation sont apprises ensemble pour optimiser directement l'objectif final de trading. Le modèle apprend simultanément à produire des signaux qui seront utiles pour l'allocation et à allouer du capital en fonction de ces signaux. Cette approche évite les biais et les sous-optimalités qui peuvent apparaitre quand on optimise chaque étape séparemment. Dans le papier, les résultats hors échantillon sur la période 2002-2026 montrent que cette approche atteint des ratios de Sharpe annualisés de 3.2 à 4.2 selon le modèle de facteurs considérés. Elle surpasse largement les benchmarks paramètriques (OU+seuil) et fréquentiels (FFT+FFN).

1.4 Résultats principaux du papier

2 Implémentation

Après avoir présenté le cadre méthodologique du papier original, nous détaillons maintenant les choix d'implémentation que nous avons retenus pour notre étude. Notre point de départ est le code source du papier, disponible sur GitHub. Nous y avons apporté des modifications dont nous expliquons les mmotivations dans cette section.

2.1 Choix de la classe d'actifs et modèle de facteurs retenu

La question s'est vite posée de savoir sur quelles classes d'actifs appliquer la méthodologie du papier. Notre premier réflexe a été de nous tourner vers les obligations. Ce choix semblait naturel puisqu'elles constituent un marché plutôt bien documenté avec beaucoup de données historiques. Cependant,

nous avons vite rencontré un problème dû à la nature même des obligations. Etant donné que chacune possède une maturité qui décroit au fil du temps, l'instrument change de nature au cours de sa vie ce qui empêche de construire des séries temporelles longues et stables pour un même actif. Par conséquent, pour constituer un lot d'obligations suffisamment large et avec un historique assez conséquent, le nombre d'instruments chute drastiquement. Il a donc fallu chercher une classe d'actifs alternatives pour laquelle le modèle pourrait fonctionner.

2.1.1 Les cryptomonnaies

Notre choix final s'est porté sur les cryptomonnaies. Elles n'ont pas de maturité. Il est donc possible de construire de longues séries temporelles. Ensuite, le marché des crypto compte un bon nombre d'actifs avec une capitalisation suffisante. Les données sont librement disponible via Binance. Cela nous permet d'appliquer la méthodologie du papier dans des conditions proches de l'original tout en introduisant une classe d'actifs aux dynamiques très différentes.

2.1.2 Pourquoi le PCA plutôt que Fama-French ou IPCA

Les modèles factoriels de type Fama-French constituent une référence incontournable. Toutefois, leur application à l'univers des cryptomonnaies pose problème. Ces facteurs reposent sur des variables comptables telles que le ratio book-to-market ou la rentabilité opérationnelle qui ne sont pas définies de manière homogène pour les cryptomonnaies. Par ailleurs, l'approche IPCA reposent sur l'utilisation d'un grand nombre de caractéristiques d'actifs (46 dans le papier). Ces dernières sont souvent extraites de bases de donnéees payantes telles que CRSP ou Compustat. Elles ne nous sont donc pas disponibles.

Dans ce contexte, l'approche PCA s'est révélé être l'approche la plus pertinente. La littérature montre que les approches basées sur le PCA peuvent atteindre des performances proches de modèles plus complexes tels que l'IPCA. De pls, le PCA est générique et peut être appliquée à différentes classes d'actifs sans adaptation structurelle.

2.2 Collecte et préparation des données

Notre étude repose sur un panel de cryptomonnaies dont nous extrayons les prix toutes les 4 heures via l'API Binance. La période d'obeservation d'étend du 1er janvier janvier 2021 au 23 avril 2026. Nous partons d'une liste de 120 cryptomonnaies. Après suppression de quelques actifs problématiques (notamment les stable coins), nous conservons 115 cryptos. Pour chacune d'elles, nous récupérons les prix de clotûre toutes les 4 heures.

2.2.1 Filtrage par capitalisation

Contrairement aux actions, il n'existe pas de capitalisation boursière officielle et immédiatement disponible. Nous la calculons donc à partir de deux sources : le prix (toutes les 4 heures), le circulating supply obtenue via l'API CoinGecko. Cette donnée étant peu volatile, elle est récupérée une seule fois par crypto.

Pour chaque date t, nous estimons la capitalisation boursière de chaque actif par :

$$\text{MarketCap}_{i,t} = \text{Prix}_{i,t} \times \text{Supply}_i$$

Nous trions ensuite les cryptos par capitalisation décroissante et ne conservons que les 40 premières à chaque date. Ce filtre dynamique par capitalisation nous permet de nous rapprocher des conditions du papier et garantit que notre uniners de trading est toujours composé des actifs les plus liquides et les plus importants du marché sans biais de sélection manuelle.

Pour chaque temps t la période hors échantillon (à partir de 2022), nous déterminons la fenêtre de covariance (252 périodes soit environ 42 jours) qui précède t. Les cryptos sont sélectionnés en suivant la méthode présentée précedemment.

2.2.2 Extraction des facteurs PCA et estimation des résidus

Sur la fenêtre de covariance, nous standardisons les rendements sélectionnés :

$$\tilde{R}_{i,\tau} = \frac{R_{i,\tau} - \mu_i}{\sigma_i}$$

Nous construisons la matrice $\mathbf{C}$ de corrélation et la diagonalisons :

$$\mathbf{C} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^\top$$

Les facteurs PCA sont les projections des rendements standardisés sur les K premiers vecteurs propres $\mathbf{V}_K$:

$$F_\tau = \mathbf{V}_K^\top \tilde{\mathbf{R}}_\tau$$

Nous estimons ensuite les loadings par régression linéaire des rendements sur les facteurs. Ce résidu constitue le portefuille d'arbitrage pour la crypto i à l'instant t. Notre algorithme calcule simultanément les résidus pour tous les nombres des facteurs K (0, 1, 3, 5, 8, 10).

2.2.3 Paramètres choisis

Nous avons choisis les differents parametres en fonction de l'etat de l'art.

- `sizeWindow = 360` périodes (60 jours de données car 6 périodes de 4h par jour)
- `sizeCovarianceWindow = 1080` périodes (environ 6 mois)
- `initialOOSYear = 2022` (On laisse environ 1 an d'historique avant la première prédiction
- `factorList = 0, 1, 3, 5, 8, 10`

Ces résidus servent d'entrée aux modèles pour l'extraction des signaux d'arbitrage.

2.3 Modèles benchmarks

Pour évaluer la performance de notre modèle CNN, nous le comparons à deux modèles plus simples évoqués plus haut. Nous reprenons le modèle Fourier+FFN et le modèle OUFFN. Toutefois, au lieu de reproduire la règle par seuil pour le modèle OU, nous avons utilisé une variante dans laquelle les mêmes signaux paramétriques sont conservés mais la décision est confiée à un réseau feedforward (FFN) constitué de 4 couches cachées avec activation sigmoïde. Cette modification rend la comparaison plus équilibrée entre les modèles puisqu'ils utilisent tous un FFN pour l'allocation. Comme dans le papier original, nous utilisons le ratio de Sharpe annualisé comme métrique de comparaison principale entre les modèles.

2.3.1 Ornstein-Uhlenbeck + Feedforward Neural Network

Pour ce modèle, nous utilisons une fenêtre de lookback de 84 périodes (soit 14 jours) ainsi qu'une longueur d'entraînement de 5000 périodes, plus longue que pour les autres modèles. Ce choix vise à disposer d'un historique suffisant pour estimer de manière fiable les paramètres du processus d'Ornstein-Uhlenbeck. L'architecture du FFN retenue est de type [4, 8, 8, 4], plus profonde que celle proposée dans le papier original. Cela permet de mieux capturer les relations non linéaires caractéristiques des marchés de cryptomonnaies, connus pour leur forte volatilité.

2.3.2 Transformation de Fourier + Feedforward Neural Network

Dans ce modèle, le paramètre de lookback joue un rôle central. Les expérimentations montrent qu'un lookback court de 24 périodes (4 jours) surperforme systématiquement les horizons plus longs testés (jusqu'à 168 périodes). Puis, au delà de ce seuil, pour des lookbacks plus courts, les performances se dégradent. Ce résultat reflète la nature essentiellement court-termiste des dynamiques de prix sur les marchés de cryptomonnaies. En cohérence avec ce choix, l'architecture du FFN est ajustée avec des couches cachées de tailles [24, 16, 8, 4].

2.3.3 CNN+Transformer

Enfin, le modèle CNN+Transformer repose sur un lookback de 42 périodes (7 jours) et utilise 8 têtes d'attention, contre 4 dans le papier de référence. Cette augmentation s'explique par la plus grande hétérogénéité des dynamiques temporelles observées sur les cryptomonnaies par rapport aux actions, nécessitant un mécanisme d'attention plus expressif.

Par ailleurs, la fonction objectif de type mean-variance s'avère nettement plus performante que l'objectif basé sur le ratio de Sharpe, avec une amélioration du Sharpe de 1.61 à 2.08. À l'inverse, pour les deux modèles de référence, le choix de la fonction objectif n'a pas d'impact significatif sur les performances. C'est pourquoi nous avons comparé les modèles avec pour fonction objectif de type mean-variance.

Le tableau ci-dessous récapitule les hyperparamètres retenus pour le meilleur run de chaque modèle.

Paramètre	OU+FFN	Fourier+FFN	CNN+Transformer
Lookback (périodes)	84	24	42
Objectif	meanvar	meanvar	meanvar
Dropout	0.3	0.4	0.5
Batch size	512	360	252
Length training	5000	3000	2000
Périodes OOS	2249	4249	5249

Table 1 – Hyperparamètres retenus pour le meilleur run de chaque modèle

2.4 Méthode d'entrainement

Une sélection des cryptomonnaies valides est d'abord effectuée, en conservant uniquement ceux disposant d'au moins 50 observations historiques non-nulles pour éviter les biais d'anticipation (look-ahead bias). Les données sont ensuite organisées sous forme de fenêtres glissantes. Pour chaque époque d'entraînement, les données sont traitées par batchs. Pour chaque batch, le modèle effectue

un forward pass qui transforme la fenêtre temporelle en poids d'allocation normalisés. Les rendements du portefeuille sont calculés en multipliant les poids par les rendements des actifs. Une métrique (sharpe par defaut) est alors transformée en fonction de perte à minimiser. Le processus d'entraînement est répété sur des fenêtres temporelles glissantes, avec réentraînement. Cette approche rolling-window simule un environnement de trading réaliste où le modèle s'adapte continuellement aux structures de marché évolutives.

3 Résultats

3.1 Comparaison des performances

Modèle	Sharpe annualisé	Rendement annualisé	Périodes OOS
CNN+Transformer	2.08	104.4%	5249
Fourier+FFN	1.11	60.8%	4249
OU+FFN	0.88	49.5%	2249

Table 2 – Performances out-of-sample des trois modèles (sans frictions de marché). Les périodes out-of-sample diffèrent selon les modèles en raison de choix d'hyperparamètres différents.

Les trois modèles présentent des ratios de Sharpe annualisés positifs et significatifs, ce qui confirme que la méthodologie du papier est applicable aux données de la cryptomonnaie. Le modèle CNN+Transformer optimisé atteint le meilleur ratio de Sharpe (2.08), suivi du OU+FFN (1.61) et du Fourier+FFN (1.11). Ces résultats sont cohérents avec ceux du papier original, dans lequel le CNN+Transformer dépasse les autres modèles. Les niveaux absolus restent toutefois inférieurs à ceux du papier : celui-ci rapporte des Sharpe de 3.2 à 4.2 avec le modèle IPCA sur actions, ce qui s'explique par les différences de classe d'actifs, de fréquence de connées et de modèle factoriel.

3.2 Analyse de la sensibilité aux hyperparamètres

Plusieurs configurations ont été testées pour chaque modèle, en faisant varier des paramètres tels que le lookback, le droupout, la longueur d'entraînement ou encore la fonction objectif. Pour tous les modèles, la fonction objectif mean-variance s'est révélée supérieure à l'objectif Sharpe, mais avec un impact très différent selon le modèle. Pour le CNN+Transformer, le gain est substantiel : le Sharpe passe de 1.61 à 2.08 en substituant l'objectif Sharpe par la mean-variance. Pour le Fourier+FFN en revanche, l'impact est négligeable — les deux objectifs donnent des performances quasi-identiques. Le lookback est également un paramètre déterminant, particulièrement pour le Fourier+FFN : un lookback court de 24 périodes (4 jours) domine systématiquement les lookbacks plus longs, ce qui reflète la nature court-termiste des dynamiques de prix sur le marché crypto.

3.3 Analyse comparative des rendements cumulés

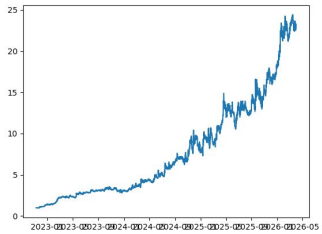

FIGURE 1 – Performance out-of-sample du modèle CNN

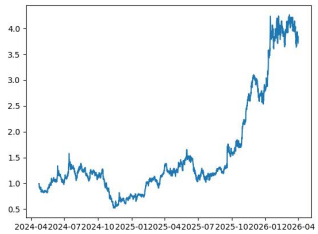

FIGURE 2 – Performance out-of-sample du modèle Fourier+FFN

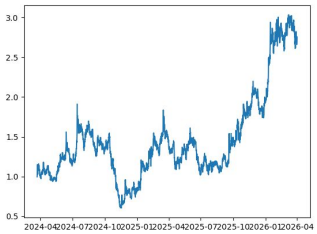

FIGURE 3 – Performance out-of-sample du modèle OU+FFN

Les trajectoires de rendements cumulés révèlent des profils distincts et permettent de comprendre la nature de chaque stratégie.

Les trajectoires des rendements présentent trois phases communes. La première est lente et assez régulière de début 2023 à mi-2024. Sur cette période, le rendement cumulé progresse de 1 à 3-4. Le modèle détecte des opportunités d'arbitrage mais elles sont limitées car le marché est peu volatile. La deuxième phase commence en mi-2024. Elle coincide avec la hausse du cours des crypto après l'approbation des ETFs Bitcoin spot aux Etats-Unis en janvier 2024. C'est à partir de ce moment que les trajectoires divergent nettement. Enfin, la troisième phase sur 2025-2026 voit les écarts s'amplifier, avec une forte accélération du CNN+Transformer tandis que le Fourier+FFN et le OU+FFN affichent des trajectoires plus heurtées. Cette dernière performance doit être interprétée avec prudence.

Le modèle CNN+Transformer affiche la meilleure performance avec un rendement cumulé atteignant approximativement $\times 24$ sur l'ensemble out-of-sample. Il affiche la progression la plus régulière et la plus soutenue sur l'ensemble de la période, avec une accélération marquée à partir de mi-2024. Ce comportement est cohérent avec sa capacité à capturer à la fois des patterns locaux via les filtres convolutionnels et des dépendances temporelles complexes via le mécanisme d'attention.

Le modèle Fourier+FFN affiche un rendement d'environ $\times 4$ sur 2 ans ce qui constitue une performance solide mais inférieur à celle du CNN+Transformer. affiche une longue période de stagnation de mi-2024 à mi-2025, cohérente avec les limites d'un modèle dont les bases fréquentielles sont pré-spécifiées. Toutefois, la reprise observée à partir de septembre 2025 indique le modèle exploite bien les déviations temporaires de prix lorsque la volatilité augmente créant plus d'opportunités d'arbitrage.

Le modèle OU+FFN présente le profil le plus atypique, avec une phase de drawdown très prononcée entre mi-2024 et début 2025 où le rendement chute de 1.9 à environ 0.6. Ce comportement vient de la fragilité du modèle de Orstein Uhlenbeck face à des dynamiques de prix qui s'écartent de l'hypothèse de mean-reversion simple. Lorsque les résidus suivent des tendances qui persistent dans le temps, comme c'est fréquemment le cas sur les marchés crypto, le modèle paramétrique génère des signaux mauvais et accumule les erreurs. La forte sensibilité du modèle aux conditions de marché et son incapacité à adapter ses paramètres aux régimes changeants des marchés crypto confirment les limites des modèles paramétriques sur cet univers d'actifs.

3.4 Analyse du turnover

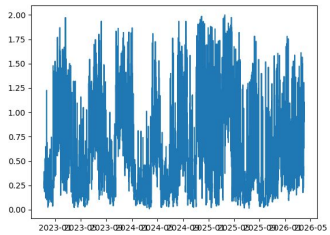

FIGURE 4 – Turnover du modèle CNN

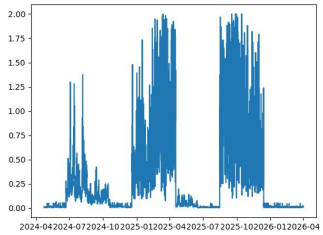

FIGURE 5 – Turnover du modèle Fourier+FFN

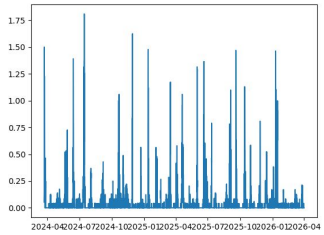

FIGURE 6 – Turnover du modèle OU+FFN

L'analyse du turnover apporte elle aussi un éclairage sur la nature de chaque stratégie. Le CNN+Transformer présente le profil le plus actif et le plus régulier. Le turnover oscille de manière quasi-continue entre 0 et 2. Ce comportement est lié à la nature du modèle. La combinaison du filtre convutionnel et du mécanisme d'attention génère des signaux fréquemment mis à jour et capture à la fois des patterns locaux et des dépendances globales à plus long terme. On observe toutefois quelques épisodes de turnover réduit qui pourraient correspondre à des phases moins propices à l'arbitrage.

Le Fourier+FFN est radicalement différent et révèle un comportement très original. On observe trois régimes différents qui alternent entre des périodes d'activité maximale et d'inactivité intenses, où le turnover atteint le maximum de 2. Le modèle semble s'activer uniquement lorsque les signaux extraits dépassent un certain seuil, puis trade massivement avant de rechuter. La trajectoire suggère que le modèle identifie des fenêtres spécifiques d'opportunités d'arbitrage plutôt que de trader en continue.

Enfin, le modèle 0U+FFN présente encore une fois le profil le plus différent. Les transactions sont rares sous forme de pics isolés. La grande majorité des jours ont un turnover proche de 0. Par ailleurs, les pics semblent distribués de manièrement relativement uniforme dans le temps sans concentration sur les phases de marché actives ce qui montre que le modèle OU ne parvient pas à discriminer les périodes favorables à l'arbitrage et celles qui ne le sont pas.

3.5 Robustesse aux frictions de marché

Nous avons évalué la robustesse des stratégies en introduisant des coûts de transaction réalistes : 0.1% par transaction et un coût de portage de 0.0003% par période pour les positions short, ce qui correspond aux conditions de marché observées sur Binance. Les résultats sont présentés dans le tableau ci-dessous.

Modèle	Sharpe sans frictions	Sharpe avec frictions	Dégradation
CNN+Transformer	2.08	0.32	-84%
Fourier+FFN	1.11	0.55	-51%
OU+FFN	0.88	0.67	-24%

TABLE 3 – Impact des frictions de marché sur les performances out-of-sample

L'introduction des frictions dégrade significativement les performances de l'ensemble des modèles, avec une sensibilité inversement proportionnelle au turnover. Le CNN+Transformer, qui présente

le turnover le plus élevé (0.62), subit la dégradation la plus forte (-84%), tandis que le OU+FFN, dont le turnover est quasi-nul (0.05), résiste mieux (-24%). Ces résultats soulignent l'importance de considérer les frictions dans l'évaluation de toute stratégie à haute fréquence et constituent une limite importante de notre implémentation.

4 Conclusion

Ce travail avait pour objectif de tester si la méthode de Guijarro-Ordonez, Pelger et Zanotti (2022) pouvait être appliquée au marché des cryptomonnaies. Nos résultats montrent que c'est bien le cas : on obtient des stratégies rentables hors échantillon, avec un classement des modèles similaire à celui du papier original. Le modèle CNN+Transformer est le plus performant, avec un ratio de Sharpe annualisé de 2.08, devant le Fourier+FFN (1.11) et le OU+FFN (0.88).

Plusieurs enseignements ressortent de cette analyse. Pour le CNN+Transformer, l'objectif mean-variance donne de meilleurs résultats que l'objectif basé sur le Sharpe, ce qui suggère qu'il est préférable de contrôler explicitement la variance dans un marché aussi volatil que celui des cryptos. De plus, les horizons temporels optimaux sont plus courts que dans l'étude originale — entre 4 et 7 jours contre environ 30 jours — ce qui reflète des dynamiques de prix plus rapides.

Nos performances restent cependant inférieures à celles du papier (Sharpe entre 3.2 et 4.2). Cela s'explique en partie par des différences de méthodologie. En particulier, nous utilisons une PCA au lieu de l'IPCA, faute de données comptables pour les cryptomonnaies, ce qui limite sans doute la qualité des facteurs. Par ailleurs, lorsque l'on prend en compte des frictions de marché réalistes, les performances diminuent fortement. C'est notamment le cas du CNN+Transformer, dont le Sharpe passe de 2.08 à 0.32, ce qui montre l'importance des coûts de transaction dans ce type de stratégie.

Enfin, plusieurs pistes d'amélioration peuvent être envisagées. Il serait intéressant de construire des facteurs spécifiques aux cryptomonnaies, par exemple en utilisant des données issues des marchés de dérivés ou des métriques on-chain, afin de se rapprocher de l'approche IPCA. De plus, il serait intéressant de se pencher davantage sur l'entrainement des modèles avec les frictions de marché.

Références

1. Deep Learning Statistical Arbitrage de Guijarro-Ordonez, Pelger et Zanotti (2022) https://arxiv.org/pdf/2106.04028
2. Statistical Arbitrage within Crypto Markets using PCA https://papers.ssrn.com/sol3/papers.cfm?abstract_id=5263475
3. Github du papier https://github.com/gregzanotti/dlsa-public